

HOMEPEDIA

Rapport de visualisation des données

Où un jeune actif doit-il acheter en France ?

Justification des visualisations, des métriques et des règles métier.

Projet **Big Data** : architecture médaillon Bronze → Silver → Gold

Epitech · **T-DAT-902** · MSc Pro : Promotion 2026

Réalisé par le **groupe PAR_5**

Juillet 2026

Sommaire

I. Problématique

II. Provenance des données

III. Les graphiques de l'application

- III.1 La carte interactive (Cartographe)
- III.2 Les 6 modes de coloration & le calque gares
- III.3 La fiche commune & le drill-down arrondissements
- III.4 La page Statistiques (7 graphiques)
- III.5 Le tableau des arrondissements
- III.6 La synthèse textuelle

IV. Justification des règles métier : pourquoi ces choix ?

- IV.1 Prix médian & filtrage DVF
- IV.2 Abordabilité (années de revenu, classes)
- IV.3 Transport & équipements
- IV.4 Score de correspondance
- IV.5 Analyse textuelle : règles plutôt que LLM

V. Architecture technique & stack

- V.1 Vue d'ensemble & pipeline médaillon
- V.2 La stack, brique par brique
- V.3 Orchestration, exécution & déploiement

VI. Méthodologie

- VI.1 Démarche projet
- VI.2 Acquisition & traitement des données
- VI.3 Qualité & gouvernance
- VI.4 Outils & collaboration

VII. Annexe : Comment chaque métrique est calculée

I. Problématique

HOMEPEIDIA aide un **jeune actif à décider où acheter un bien en France**. La difficulté n'est pas le manque de données, mais leur **lecture** : un prix au m² seul ne dit pas si un quartier est abordable au regard des revenus, bien desservi, équipé, ou peuplé de « gens comme moi ».

Chaque visualisation du front existe pour transformer une de ces questions en une **décision**. Ce rapport justifie, pour chaque graphique, le **choix de la métrique**, son utilité, son lien à la problématique et son **mode de calcul**.

II. Provenance des données

La donnée provient de la **couche Gold** (PostgreSQL pré-agrégé, architecture médaillon Bronze → Silver → Gold), consommée via une API. Elle croise **quatre axes de décision** :

- **Prix & abordabilité** : DVF (Etalab) × revenus FiLoSoFi (INSEE) ;
- **Transport** : gares SNCF (open data) ;
- **Services & commerces** : équipements BPE (INSEE) ;
- **Démographie** : recensement INSEE.

Les visualisations sont organisées autour de ces quatre axes.

III. Les graphiques de l'application

III.1 La carte interactive (Cartographe)

C'est la **vue d'entrée**. Elle colore chaque commune d'Île-de-France (ou chaque département en vue « France ») et répond à la question centrale : « **où, sur le territoire, dois-je regarder ?** ». Sa force est de superposer tous les critères sur une même lecture spatiale.




Fig. 1 : Cartographe. Choroplèthe d'Île-de-France colorée par score de correspondance (vert = meilleure adéquation), panneau de critères / pondérations à gauche, communes recommandées classées à droite.

Le score de correspondance personnalisé (0–100)

Métrique phare : un **score unique** qui synthétise l'adéquation d'une commune au profil de l'utilisateur. Il agrège quatre sous-scores : **budget, transport, services, jeunes actifs** : chacun normalisé entre 0 et 1, puis combinés en **moyenne pondérée** par les curseurs d'importance que l'utilisateur règle lui-même (les dimensions sans donnée sont exclues du calcul). La couleur va du vert (excellent, ≥ 75) au rouge (hors cible, < 25).

Pourquoi : c'est la traduction directe de la problématique : au lieu de comparer mentalement cinq indicateurs, l'utilisateur voit **une carte à son image**. En déplaçant les curseurs (« le budget compte plus que le transport »), il voit la carte se recolorer : la décision devient exploratoire et personnelle.

Comment le score est calculé, pas à pas

1. On note chaque dimension de 0 à 100.

- **Budget** : l'utilisateur saisit un budget et une surface, d'où un prix cible €/m² (= budget ÷ surface). Une commune nettement *moins chère* que la cible obtient une note élevée ; une commune *au-dessus*, une note faible. Sans budget saisi, on reprend la classe d'abordabilité (Très abordable ≈ 100 ... Très tendu ≈ 15).
- **Transport** : d'après la classe de desserte : Hub majeur 100, Bien desservie 80, Desservie 55, Non desservie 10, *moins* une pénalité si la gare la plus proche est à plus de 2 km.
- **Services** : d'après le niveau d'équipement : Très équipée 100, Bien équipée 75, Équipée 50, Sous-équipée 20.
- **Jeunes actifs** : part de population active (25-64 + moins de 25) ramenée sur 100 : 50 % → 0, 85 % → 100.

2. On fait la moyenne pondérée de ces quatre notes par les curseurs d'importance (Budget / Transport / Services / Ambiance jeune). Une dimension sans donnée est simplement retirée de la moyenne.

Exemple. Notes 80 / 80 / 75 / 60 et poids par défaut 60 / 50 / 40 / 30 → $(80 \cdot 60 + 80 \cdot 50 + 75 \cdot 40 + 60 \cdot 30) \div (60 + 50 + 40 + 30) = 13\,600 \div 180 \approx \mathbf{76 / 100}$: commune affichée en vert sur la carte.

III.2 Les 6 modes de coloration & le calque gares

La même carte se relit selon un seul critère à la fois : **Mon score**, **Prix au m²**, **Abordabilité**, **Transport**, **Équipements**, **Jeunes actifs**. Chaque mode a sa propre échelle de couleur et sa légende (verrouillées ensemble dans le code pour ne jamais diverger). Un **calque de gares** (points cliquables) se superpose pour juger la desserte fine. Les **filtres durs** (desserte minimale, distance max à une gare, niveau d'équipement minimal) grisent les communes hors critères, et une **liste de recommandations** classe les meilleures.

Pourquoi : un jeune actif ne pondère pas tout pareil. Les modes permettent d'isoler *le* critère décisif du moment (« montre-moi seulement l'abordabilité »), tandis que les filtres durs éliminent d'emblée l'inacceptable (« pas de bien à plus de 2 km d'une gare »).

III.3 La fiche commune & le drill-down arrondissements

Cliquer une commune ouvre une **fiche** : score et ses 4 sous-scores en barres, **surface atteignable** avec le budget saisi (budget ÷ prix_m2 local), mini-courbe de tendance, transport, équipements et pyramide d'âge. Pour Paris, Lyon et Marseille, un **drill-down** descend à l'arrondissement : seule granularité infra-communale disponible.

Pourquoi : la carte donne la vue d'ensemble ; la fiche donne les **informations concrètes pour décider** sur une zone précise, dont le message le plus parlant pour un acheteur : « avec votre

budget, ici, vous pourriez acheter $\approx X \text{ m}^2$ ».

III.4 La page Statistiques (7 graphiques)

Elle approfondit une zone choisie (Paris par défaut, ou « France entière » en agrégat pondéré). Les graphiques sont groupés en trois blocs.

Prix & marché

- **Bandeau d'indicateurs (KPIs)** : prix médian (+ variation vs mois précédent), classe d'abordabilité (+ années de revenu), revenu médian, population, desserte, niveau d'équipement. **Pourquoi** : un résumé chiffré en un coup d'œil des six dimensions de décision, avant tout graphique.
- **Prix médian mensuel** (barres) : année en cours vs année précédente, avec le Δ . **Pourquoi** : montre la **dynamique** du marché : acheter dans un marché qui grimpe vite est plus risqué (pouvoir d'achat qui s'érode) qu'un marché stable.
- **Historique annuel** (ligne prix médian + barres volume de ventes). **Pourquoi** : recontextualise le prix sur plusieurs millésimes et croise avec le **volume de transactions** : un prix appuyé sur peu de ventes est moins fiable.
- **Répartition par type** (donut) : part des transactions Appartement vs Maison. **Pourquoi** : indique la réalité du marché local : à Paris, chercher une maison n'a guère de sens ; le donut le rend évident.
- **Prix par type de bien** (barres) : prix médian €/m² Maison vs Appartement + surface médiane. **Pourquoi** : le budget se raisonne par type ; l'écart de prix oriente le choix Appartement / Maison.

Cadre de vie

- **Profil de population** (donut) : répartition par âge (-25 / 25-64 / 65+). **Pourquoi** : matche la cible « jeunes actifs » : une zone jeune et active est un signal d'adéquation de mode de vie.
- **Services & commerces** (barres) : comptages d'équipements Santé, Commerces, Enseignement, Supermarchés. **Pourquoi** : la qualité de vie quotidienne se lit dans la proximité des services ; un quartier abordable mais sous-équipé n'est pas un bon compromis.

Correspondance

- **Radar de correspondance** : les 4 sous-scores (Budget, Transport, Services, Jeunes actifs) + le score global. **Pourquoi** : boucle la page vers le cœur produit : d'un coup d'œil, on voit **sur quel axe** une zone est forte ou faible, sans lire cinq chiffres.

III.5 Le tableau des arrondissements

Une table triable / filtrable des **45 arrondissements** de Paris, Lyon et Marseille : prix médian, surface, revenu, population, transactions, **années de revenu**, m²/an, classe d'abordabilité : avec export CSV.

Pourquoi : la carte est faite pour explorer, le tableau pour **comparer et classer** précisément (« trier tous les arrondissements du plus abordable au plus tendu »). C'est aussi la seule vue qui exploite la granularité **infra-communale** de la couche Gold, essentielle pour un choix intra-Paris.

H

HOMEPIEDIA

MENU

Cartographie

Statistiques

Tableau

Analyse

AUTRES

Paramètres

Aide

N

Se connecter

Tableau des arrondissements

Données live

Comparez prix, revenus, démographie et abordabilité — triez chaque colonne, filtrez par ville.

Toutes

Paris

Lyon

Marseille

Rechercher...

CSV

#	Arrondissement ↕	Prix médian €/m²	Surface méd.	Revenu médian	Population ↕	Transactions ↕	Années de revenu	m² / an	Abordabilité ↕
1	Paris 6e 75106	13680 €	46 m²	48110 €	40432	604	19,9 ans	3,5	Très tendu
2	Paris 7e 75107	13077 €	53 m²	52840 €	48196	655	17,3 ans	4	Tendu
3	Paris 4e 75104	12400 €	43 m²	37400 €	28039	430	23,2 ans	3	Très tendu
4	Paris 1er 75101	12240 €	45 m²	39320 €	15475	228	21,8 ans	3,2	Très tendu
5	Paris 8e 75108	11782 €	65 m²	51690 €	35418	535	16 ans	4,4	Tendu
6	Paris 3e 75103	11667 €	40 m²	38940 €	32772	532	21 ans	3,3	Très tendu
7	Paris 5e 75105	11667 €	37 m²	40290 €	55925	758	20,3 ans	3,5	Très tendu
8	Paris 2e 75102	11000 €	37 m²	38050 €	20433	325	20,2 ans	3,5	Très tendu
9	Paris 16e 75116	10722 €	69 m²	49030 €	159733	1939	15,3 ans	4,6	Tendu

Fig. 2 : Tableau des arrondissements. Comparaison triable colonne par colonne (ici Paris, par prix décroissant) ; la pastille colorée encode la classe d'abordabilité, export CSV en un clic.

III.6 La synthèse textuelle

Un **moteur à base de règles** (seuils + gabarits, sans IA) traduit les chiffres d'une commune en analyse rédigée : un paragraphe de synthèse puis des cartes thématiques (abordabilité, marché, transport, équipements, démographie, tendance), chacune comparée à la moyenne nationale et colorée par tonalité (favorable / neutre / vigilance).

Pourquoi : toute la richesse des données ne sert à rien si l'utilisateur ne sait pas l'interpréter. La synthèse rend la donnée **lisible pour un non-expert** ; basée sur des règles, elle est **déterministe et explicable** (même entrée → même texte), contrairement à une génération par LLM.

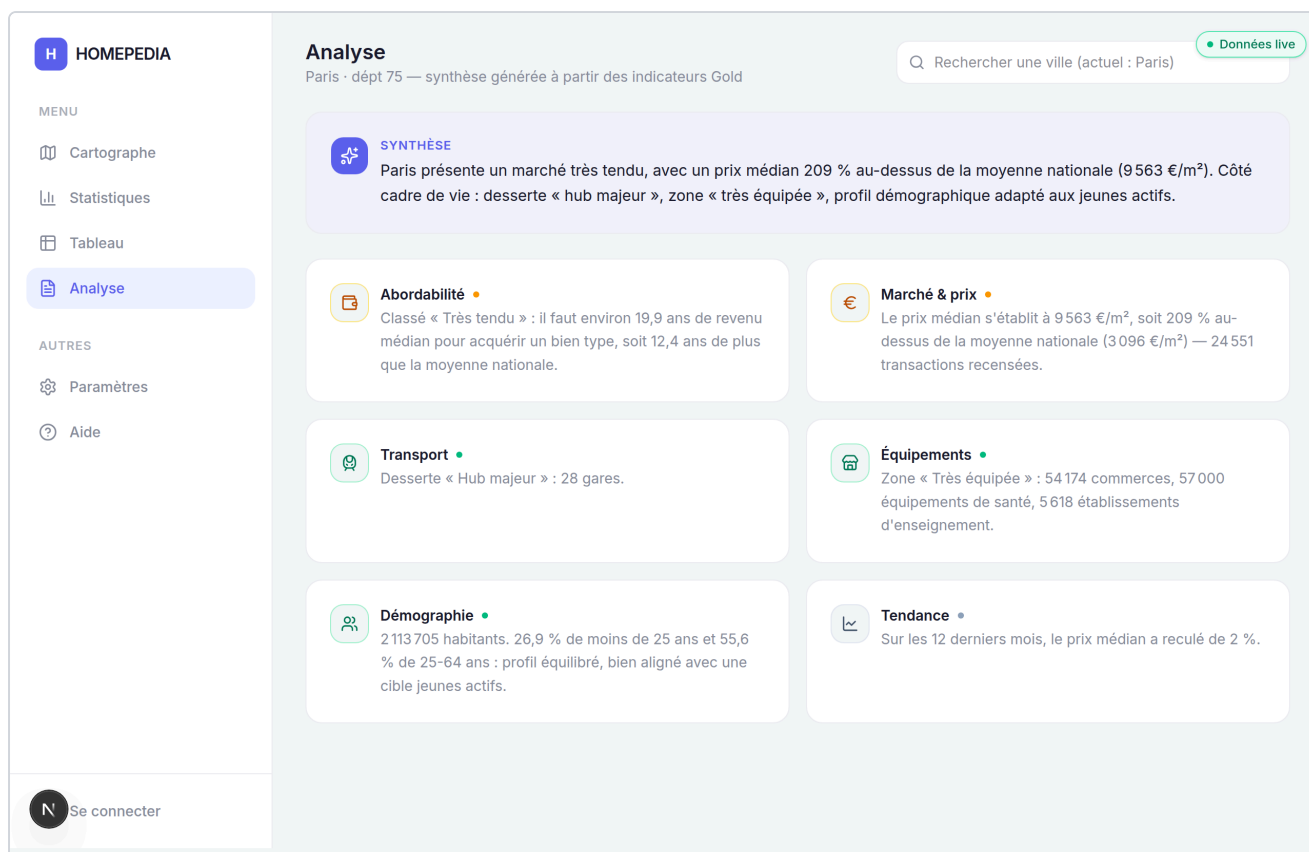


Fig. 3 : Analyse textuelle. Une synthèse de tête puis une carte par thème (abordabilité, marché, transport, équipements, démographie, tendance), chacune comparée à la moyenne nationale et colorée par tonalité.

IV. Justification des règles métier : pourquoi ces choix ?

Au-delà du *comment* (annexe en fin de rapport), chaque règle a été retenue pour trois qualités : rester **lisible** pour un non-expert, **robuste** aux défauts des données ouvertes, et **comparable** d'une commune à l'autre. Pour chacune, on explicite l'**alternative écartée** et la raison.

IV.1 Prix médian & filtrage DVF

Médiane, pas moyenne.

Pourquoi : les prix immobiliers forment une distribution **asymétrique à droite** (quelques ventes de luxe). La médiane (la valeur du milieu : autant de ventes en dessous qu'au-dessus) reflète la transaction *typique* que rencontrera l'acheteur.

Plutôt que : la moyenne, tirée vers le haut par les biens d'exception, gonfle le prix « normal » et fausse la comparaison entre communes.

Bornes anti-aberrant [500 ; 20 000] €/m².

Pourquoi : DVF contient des erreurs de saisie et des mutations non-standard (parkings, dépendances) aux €/m² absurdes ; des bornes fixes les écartent de façon **stable et reproductible**.

Plutôt que : un filtrage statistique par commune (IQR / z-score) serait instable sur les communes à faible volume de ventes et moins auditable.

Filtre « mono-bien ».

Pourquoi : une mutation peut regrouper plusieurs lots (vente d'immeuble) : son €/m² global n'a pas de sens. On ne garde que les ventes d'un **logement unique**, seules réellement comparables.

Plutôt que : diviser la valeur totale par la surface d'une vente multi-lots injecterait un prix au m² bruité et biaisé.

IV.2 Abordabilité (années de revenu, classes)

Logement type fixe de 70 m².

Pourquoi : figer la taille du « panier » rend les communes comparables sur un **même bien de référence** (≈ 2-3 pièces, cible d'un jeune ménage).

Plutôt que : indexer sur la surface médiane *locale* mélangerait « moins cher » et « plus petit », cassant la comparabilité inter-communes.

Années de revenu = $\text{prix_m2} \times 70 / \text{revenu_median}$.

Pourquoi : « combien d'années de revenu pour un logement type » est **intuitif et sans hypothèse** de taux ni de durée de prêt : donc explicable et stable dans le temps.

Plutôt que : un taux d'effort mensuel (mensualité ÷ revenu) dépendrait du taux d'intérêt et de la durée du prêt : plus fragile, daté, et moins pédagogique.

Seuils 7 / 12 / 18 ans.

Pourquoi : ancrés sur des repères d'accession réels : <7 finançable confortablement, 7-12 territoire d'un prêt standard (20-25 ans, effort tenable), 12-18 tendu, ≥18 hors de portée pour un jeune acheteur. Des seuils **absolus** donnent une lecture stable dans le temps et l'espace.

Plutôt que : des classes par quantiles de la distribution ne seraient pas comparables d'une année ou d'une région à l'autre, et « 3^e quartile » ne parle pas à un acheteur.

IV.3 Transport & équipements

Desserte 100 / 80 / 55 / 10 + pénalité au-delà de 2 km.

Pourquoi : barème **non-linéaire** : l'écart hub ↔ bien desservie est faible, mais « non desservie » est quasi rédhibitoire pour un jeune actif sans voiture. Le seuil de 2 km ≈ distance à pied/vélo raisonnable vers la gare.

Plutôt que : un espacement linéaire égal traiterait « non desservie » comme un simple cran de moins ; ignorer la distance ferait scorer pareil deux communes « desservies » avec une gare à 0,2 km et à 3 km.

Niveau d'équipement 100 / 75 / 50 / 20.

Pourquoi : classes dérivées des comptages BPE, avec un **plancher bas (20)** qui marque nettement une commune sous-équipée dans le score.

Plutôt que : le comptage brut d'équipements n'est pas normalisé (une grande ville domine mécaniquement) et n'est pas combinable aux autres notes.

IV.4 Score de correspondance

Moyenne pondérée par curseurs, dimensions manquantes exclues.

Pourquoi : l'arbitrage (budget vs transport...) **appartient à l'utilisateur** ; exclure une dimension sans donnée évite de pénaliser une commune pour un simple trou de données.

Plutôt que : des poids fixes ne seraient pas personnels (contraire à la « carte à son image ») ; imputer les valeurs manquantes introduirait un biais silencieux.

Jeunes actifs : 50 % → 0, 85 % → 100.

Pourquoi : bornes plausibles de la part active : en-dessous de 50 % la zone vieillit, 85 % = très jeune/active. Un rescale linéaire entre ces bornes donne une note 0-100 **combinable**.

Plutôt que : le pourcentage brut n'est pas normalisé et ne se combine pas aux trois autres notes.

IV.5 Analyse textuelle : règles plutôt que LLM

Moteur à seuils + gabarits, déterministe.

Pourquoi : reproductible (même entrée → même texte), **explicable et auditable**, sans hallucination ni coût/latence d'API : indispensable pour un rendu où chaque phrase doit être justifiable.

Plutôt que : une génération par LLM serait non-déterministe, risquerait d'inventer des chiffres, et serait plus difficile à défendre et à reproduire.

V. Architecture technique & stack

HOMEPEPEDIA repose sur une **architecture médaillon** (Bronze → Silver → Gold) : chaque couche a une responsabilité unique, ce qui rend la chaîne rejouable, testable et découplée. Un plan de **service** (API + front) est séparé du plan de **calcul** (Spark), pour maîtriser les coûts et la charge.

En clair. Imaginez une chaîne de raffinage : on collecte des matériaux *bruts* (Bronze), on les *nettoie et les met en forme* (Silver), puis on prépare des *produits finis prêts à consommer* (Gold). Le site web ne fait que « lire » ces produits finis déjà préparés, ce qui le rend rapide.




Fig. 4 : Architecture d'ensemble. De gauche à droite : les sources de données ouvertes, la couche Bronze (stockage brut), la couche Silver (nettoyage par Spark), la couche Gold (base PostgreSQL), le cache Redis, l'API et le frontend — le tout piloté en haut par l'orchestrateur Airflow.

Glossaire express (pour lecteur non technique)

- **Architecture médaille :** on raffine la donnée en 3 niveaux de qualité croissante (Bronze → Silver → Gold), comme un minerai que l'on affine.
- **Bronze / Silver / Gold :** donnée brute / nettoyée / prête à l'emploi.
- **Object store (S3) :** un très grand disque de stockage en ligne pour fichiers.
- **ETL :** « Extraire, Transformer, Charger » — la chaîne de préparation de la donnée.
- **Spark :** un moteur qui traite de gros volumes en les découpant en morceaux.
- **Parquet :** un format de fichier compact et rapide à relire.
- **Agrégat :** des chiffres calculés d'avance (médianes, comptages par commune).
- **API :** la « prise » par laquelle le site récupère les données.
- **Cache (Redis) :** une mémoire ultra-rapide qui garde les réponses fréquentes.
- **DAG / Airflow :** un chef d'orchestre qui lance les tâches dans le bon ordre, à heure fixe.
- **Conteneur (Docker) :** une « boîte » qui embarque l'appli et tout son nécessaire, identique partout.
- **CI/CD :** l'automatisation qui teste et met en ligne le code à chaque modification.

V.1 Vue d'ensemble & pipeline médaille

- **Bronze :** la donnée brute des sources ouvertes est déposée telle quelle sur un **object store S3** (MinIO en dev, S3 en prod). Source de vérité rejouable : on relance tout le pipeline sans re-télécharger.
- **Silver :** **Spark** nettoie, filtre les aberrations, normalise et écrit du **Parquet** colonne (une ligne par entité : commune, gare, équipement...).
- **Gold :** des **agrégats par commune** × **année** pré-calculés dans **PostgreSQL**, en 4 schémas (**market**, **demographics**, **mobility**, **services**). L'API lit ce Gold directement : aucun calcul

à la requête.

V.2 La stack, brique par brique

Brique	Techno		Rôle & justification
Object store	MinIO / S3		Stockage Bronze/Silver ; API S3 standard, découplée du calcul.
Traitement	Apache Spark 3.5		Nettoyage distribué du Silver ; encaisse la volumétrie DVF (millions de lignes).
Gold servi	PostgreSQL 16		Relationnel + JSON ; Gold pré-agrégé donc léger : simplicité d'exploitation (plutôt qu'une base OLAP).
Cache	Redis 7		Met en cache les réponses API les plus lues (carte France).
API	FastAPI		Lecture seule du Gold ; documentation OpenAPI automatique.
Frontend	Next.js 16		Carte + tableaux de bord ; rendu serveur, comptes gérés côté front.
Orchestration	Apache 2.10	Airflow	3 DAGs mensuels, dépendances explicites, tests de qualité des données, retries.
Calcul à la demande	GCP Engine	Compute	VM Spark allumée/éteinte par Airflow : on ne paie que pendant les runs.
Gouvernance	OpenMetadata		Catalogue + lignage des jeux de données.
Livraison	GitHub Actions + GHCR		Build/push de 4 images, déploiement automatisé du VPS.
Reverse-proxy	Caddy		HTTPS automatique (Let's Encrypt) devant l'API et le front.

V.3 Orchestration, exécution & déploiement

Airflow (sur le VPS) orchestre trois DAGs mensuels — `housing_etl`, `mobility_etl`, `amenities_etl` — chacun enchaînant *ingestion* : *Bronze*→*Silver* : *Silver*→*Gold* : *contrôle qualité* : *rafraîchissement du cache*. Pour le calcul lourd, Airflow **démarre une VM Spark sur GCP** avant le run, y exécute les `spark-submit` par SSH — **un job à la fois** pour ne pas saturer la machine — puis **éteint la VM** (même en cas d'échec).

En production, tout est conteneurisé. Un **VPS** héberge le plan de service (Caddy, API, front, Redis, Airflow) ; la **VM GCP** héberge le plan de calcul (Spark). La **CI/CD GitHub Actions** construit et publie quatre images sur GHCR, puis met à jour le VPS. Les secrets ne sont jamais dans le code (injectés au déploiement).

VI. Méthodologie

Le projet a été mené de façon **incrémentale, domaine par domaine** : plutôt que de tout ingérer d'un coup, on a livré une première verticale complète (prix DVF), puis répliqué le schéma aux autres domaines (transport, services, démographie).

VI.1 Démarche projet

- **Verticale d'abord** : une source menée de bout en bout (Bronze → Gold → API → front) avant d'élargir, pour valider l'architecture tôt.
- **Réplication** : chaque nouveau domaine réutilise le même patron de pipeline (mêmes opérateurs Airflow, même structure Silver/Gold).
- **Dev/prod symétriques** : le même code tourne en local (conteneur Spark) et en prod (VM GCP) ; la bascule est isolée dans un module, pas dispersée dans les DAGs.

VI.2 Acquisition & traitement des données

Les sources sont toutes **publiques** (DVF, INSEE FiLoSoFi / recensement / BPE, SNCF). L'**ingestion** dépose le brut en Bronze ; le **nettoyage Silver** applique les règles métier justifiées en section IV (bornes anti-aberrantes, filtre mono-bien, médiane...) ; l'**agrégation Gold** pré-calcul les indicateurs par commune × année. Des scripts de **backfill** permettent de (re)charger un millésime à la demande.

VI.3 Qualité & gouvernance

- **Tests de qualité des données** : des règles déclaratives (YAML) — complétude, plages de valeurs, fraîcheur — vérifiées dans les DAGs. Une règle critique qui casse **fait échouer** le run : pas de donnée fausse publiée en Gold.
- **Lignage** : OpenMetadata catalogue les jeux de données et trace le parcours source → Silver → Gold.
- **Reproductibilité** : le pipeline est conçu pour que **les mêmes entrées produisent toujours les mêmes sorties** — condition indispensable pour auditer un résultat et le défendre. Plusieurs choix y concourent :
 - **Règles déterministes** : bornes fixes ([500 ; 20 000]), seuils absolus (7 / 12 / 18 ans), logement type de 70 m² — aucun calcul ne dépend d'un tirage aléatoire ni de la distribution locale du moment.
 - **Bronze immuable** : la donnée brute est stockée telle quelle et n'est jamais modifiée ; on peut rejouer tout le pipeline à l'identique depuis cette source de vérité.
 - **Millésimes explicites** : chaque exécution cible une année précise (paramètre `year`), donc on régénère exactement le Gold d'un millésime donné, sans ambiguïté sur les données utilisées.

- **Environnement figé** : les mêmes images Docker (versions verrouillées de Spark, Python et des librairies) tournent en dev et en prod — pas de dérive liée à la machine ou à une mise à jour d'outil.
- **Code versionné** : toute la logique de transformation est sous Git ; un même commit régénère le même résultat, et on peut remonter à la version exacte qui a produit une donnée.
- **Analyse textuelle sans IA** : le moteur à règles garantit qu'une même commune donne toujours le même texte (contrairement à un LLM, non déterministe).

VI.4 Outils & collaboration

- **Versioning & CI** : Git + GitHub Actions (lint, build, déploiement).
- **Reproductibilité d'environnement** : tout est conteneurisé (Docker Compose en dev, images publiées en prod) ; un `taskfile` raccourcit les commandes courantes.
- **Secrets** : hors du code (`.env` gitignoré en dev, secrets GitHub injectés en prod).

VII. Annexe : Comment chaque métrique est calculée

Métrique	Calcul	Source · Millésime
Prix médian au m² <code>prix_m2_median</code>	Filtre « mono-bien », puis <code>prix_m2 = valeur_fonciere / surface_reelle_bati</code> , bornes anti-aberrant <code>[500 ; 20 000]</code> €, puis médiane par commune × année.	DVF (Etalab) · 2021/2022/2024
Années de revenu <code>affordability_years</code>	<code>prix_m2 × 70 / revenu_median</code> : nombre d'années de revenu médian pour un logement type de 70 m².	DVF × FiLoSoFi · revenu 2023
m² par an <code>m2_par_an</code>	<code>revenu_median / prix_m2</code> : m² achatables avec un an de revenu médian.	DVF × FiLoSoFi
Classe d'abordabilité <code>affordability_class</code>	Seuils sur les années de revenu : Très abordable <7 · Abordable 7–12 · Tendru 12–18 · Très tendu ≥18.	Dérivé de <code>affordability_years</code>
Desserte <code>desserte_class</code>	Segment SNCF de la gare (A = Hub majeur, B = Bien desservie, C = Desservie) ; sans gare → Non desservie + distance haversine (à vol d'oiseau) à la plus proche.	SNCF open data · 2024
Niveau d'équipement <code>niveau_equipement</code>	Dérivé des comptages d'équipements (Santé, Commerces, Enseignement, Supermarchés...) par commune → Sous-équipée ... Très équipée.	BPE (INSEE)

Métrique	Calcul	Source · Millésime
Structure par âge pct_moins25 / 25_64 / 65plus	Parts (%) de tranches d'âge disjointes, agrégées en 3 classes.	Recensement INSEE · 2022
Score de correspondance (calculé côté front)	Moyenne pondérée de 4 notes 0–100 (budget, transport, services, jeunes actifs) par les curseurs d'importance de l'utilisateur : détail et exemple dans l'encadré « pas à pas » (III.1).	Front · scoring.ts
Variation mensuelle (Δ)	Écart en % entre les deux derniers mois disponibles de la série de tendance.	DVF (trend mensuel)

Les métriques catégorielles (abordabilité, desserte, équipement, démographie) sont pré-calculées dans la couche Gold et lues par l'API ; le score de correspondance et les variations sont calculés côté front.

Sources : docs/fiche_ville.md, docs/silver_dvf_logic.md, frontend/src/lib/scoring.ts, analysis.ts, map-modes.ts.

HOMEPEdia · Epitech T-DAT-902.