

HOMEPEDIA

Rapport de visualisation des données

Où un jeune actif doit-il acheter en France ?

Justification des visualisations, des métriques et des règles métier.

Projet **Big Data** : architecture médaillon Bronze → Silver → Gold

Epitech · **T-DAT-902** · MSc Pro : Promotion 2026

Réalisé par le **groupe PAR_5**

Juillet 2026

Sommaire

I. Problématique

II. Provenance des données

III. Les graphiques de l'application

- III.1 La carte interactive (Cartographe)
- III.2 Les 6 modes de coloration & le calque gares
- III.3 La fiche commune & le drill-down arrondissements
- III.4 La page Statistiques (7 graphiques)
- III.5 Le tableau des arrondissements
- III.6 La synthèse textuelle

IV. Justification des règles métier : pourquoi ces choix ?

- IV.1 Prix médian & filtrage DVF
- IV.2 Abordabilité (années de revenu, classes)
- IV.3 Transport & équipements
- IV.4 Score de correspondance
- IV.5 Analyse textuelle : règles plutôt que LLM

V. Annexe : Comment chaque métrique est calculée

I. Problématique

HOMEPEIDIA aide un **jeune actif à décider où acheter un bien à Paris / en Île-de-France**. La difficulté n'est pas le manque de données, mais leur **lecture** : un prix au m² seul ne dit pas si un quartier est abordable au regard des revenus, bien desservi, équipé, ou peuplé de « gens comme moi ».

Chaque visualisation du front existe pour transformer une de ces questions en une **décision**. Ce rapport justifie, pour chaque graphique, le **choix de la métrique**, son utilité, son lien à la problématique et son **mode de calcul**.

II. Provenance des données

La donnée provient de la **couche Gold** (PostgreSQL pré-agrégé, architecture médaillon Bronze → Silver → Gold), consommée via une API. Elle croise **quatre axes de décision** :

- **Prix & abordabilité** : DVF (Etalab) × revenus FiLoSoFi (INSEE) ;
- **Transport** : gares SNCF (open data) ;
- **Services & commerces** : équipements BPE (INSEE) ;
- **Démographie** : recensement INSEE.

Les visualisations sont organisées autour de ces quatre axes.

III. Les graphiques de l'application

III.1 La carte interactive (Cartographie)

C'est la **vue d'entrée**. Elle colore chaque commune d'Île-de-France (ou chaque département en vue « France ») et répond à la question centrale : « **où, sur le territoire, dois-je regarder ?** ». Sa force est de superposer tous les critères sur une même lecture spatiale.




Fig. 1 : Cartographe. Choroplèthe d'Île-de-France colorée par score de correspondance (vert = meilleure adéquation), panneau de critères / pondérations à gauche, communes recommandées classées à droite.

Le score de correspondance personnalisé (0–100)

Métrique phare : un **score unique** qui synthétise l'adéquation d'une commune au profil de l'utilisateur. Il agrège quatre sous-scores : **budget, transport, services, jeunes actifs** : chacun normalisé entre 0 et 1, puis combinés en **moyenne pondérée** par les curseurs d'importance que l'utilisateur règle lui-même (les dimensions sans donnée sont exclues du calcul). La couleur va du vert (excellent, ≥ 75) au rouge (hors cible, < 25).

Pourquoi : c'est la traduction directe de la problématique : au lieu de comparer mentalement cinq indicateurs, l'utilisateur voit **une carte à son image**. En déplaçant les curseurs (« le budget compte plus que le transport »), il voit la carte se recolorer : la décision devient exploratoire et personnelle.

Comment le score est calculé, pas à pas

1. On note chaque dimension de 0 à 100.

- **Budget** : l'utilisateur saisit un budget et une surface, d'où un prix cible €/m² (= budget ÷ surface). Une commune nettement *moins chère* que la cible obtient une note élevée ; une commune *au-dessus*, une note faible. Sans budget saisi, on reprend la classe d'abordabilité (Très abordable ≈ 100 ... Très tendu ≈ 15).
- **Transport** : d'après la classe de desserte : Hub majeur 100, Bien desservie 80, Desservie 55, Non desservie 10, *moins* une pénalité si la gare la plus proche est à plus de 2 km.
- **Services** : d'après le niveau d'équipement : Très équipée 100, Bien équipée 75, Équipée 50, Sous-équipée 20.
- **Jeunes actifs** : part de population active (25-64 + moins de 25) ramenée sur 100 : 50 % → 0, 85 % → 100.

2. On fait la moyenne pondérée de ces quatre notes par les curseurs d'importance (Budget / Transport / Services / Ambiance jeune). Une dimension sans donnée est simplement retirée de la moyenne.

Exemple. Notes 80 / 80 / 75 / 60 et poids par défaut 60 / 50 / 40 / 30 → $(80 \cdot 60 + 80 \cdot 50 + 75 \cdot 40 + 60 \cdot 30) \div (60 + 50 + 40 + 30) = 13\,600 \div 180 \approx \mathbf{76 / 100}$: commune affichée en vert sur la carte.

III.2 Les 6 modes de coloration & le calque gares

La même carte se relit selon un seul critère à la fois : **Mon score**, **Prix au m²**, **Abordabilité**, **Transport**, **Équipements**, **Jeunes actifs**. Chaque mode a sa propre échelle de couleur et sa légende (verrouillées ensemble dans le code pour ne jamais diverger). Un **calque de gares** (points cliquables) se superpose pour juger la desserte fine. Les **filtres durs** (desserte minimale, distance max à une gare, niveau d'équipement minimal) grisent les communes hors critères, et une **liste de recommandations** classe les meilleures.

Pourquoi : un jeune actif ne pondère pas tout pareil. Les modes permettent d'isoler *le* critère décisif du moment (« montre-moi seulement l'abordabilité »), tandis que les filtres durs éliminent d'emblée l'inacceptable (« pas de bien à plus de 2 km d'une gare »).

III.3 La fiche commune & le drill-down arrondissements

Cliquer une commune ouvre une **fiche** : score et ses 4 sous-scores en barres, **surface atteignable** avec le budget saisi (budget ÷ prix_m2 local), mini-courbe de tendance, transport, équipements et pyramide d'âge. Pour Paris, Lyon et Marseille, un **drill-down** descend à l'arrondissement : seule granularité infra-communale disponible.

Pourquoi : la carte donne la vue d'ensemble ; la fiche donne les **informations concrètes pour décider** sur une zone précise, dont le message le plus parlant pour un acheteur : « avec votre

budget, ici, vous pourriez acheter $\approx X \text{ m}^2$ ».

III.4 La page Statistiques (7 graphiques)

Elle approfondit une zone choisie (Paris par défaut, ou « France entière » en agrégat pondéré). Les graphiques sont groupés en trois blocs.

Prix & marché

- **Bandeau d'indicateurs (KPIs)** : prix médian (+ variation vs mois précédent), classe d'abordabilité (+ années de revenu), revenu médian, population, desserte, niveau d'équipement. **Pourquoi** : un résumé chiffré en un coup d'œil des six dimensions de décision, avant tout graphique.
- **Prix médian mensuel** (barres) : année en cours vs année précédente, avec le Δ . **Pourquoi** : montre la **dynamique** du marché : acheter dans un marché qui grimpe vite est plus risqué (pouvoir d'achat qui s'érode) qu'un marché stable.
- **Historique annuel** (ligne prix médian + barres volume de ventes). **Pourquoi** : recontextualise le prix sur plusieurs millésimes et croise avec le **volume de transactions** : un prix appuyé sur peu de ventes est moins fiable.
- **Répartition par type** (donut) : part des transactions Appartement vs Maison. **Pourquoi** : indique la réalité du marché local : à Paris, chercher une maison n'a guère de sens ; le donut le rend évident.
- **Prix par type de bien** (barres) : prix médian €/m² Maison vs Appartement + surface médiane. **Pourquoi** : le budget se raisonne par type ; l'écart de prix oriente le choix Appartement / Maison.

Cadre de vie

- **Profil de population** (donut) : répartition par âge (-25 / 25-64 / 65+). **Pourquoi** : matche la cible « jeunes actifs » : une zone jeune et active est un signal d'adéquation de mode de vie.
- **Services & commerces** (barres) : comptages d'équipements Santé, Commerces, Enseignement, Supermarchés. **Pourquoi** : la qualité de vie quotidienne se lit dans la proximité des services ; un quartier abordable mais sous-équipé n'est pas un bon compromis.

Correspondance

- **Radar de correspondance** : les 4 sous-scores (Budget, Transport, Services, Jeunes actifs) + le score global. **Pourquoi** : boucle la page vers le cœur produit : d'un coup d'œil, on voit **sur quel axe** une zone est forte ou faible, sans lire cinq chiffres.

III.5 Le tableau des arrondissements

Une table triable / filtrable des **45 arrondissements** de Paris, Lyon et Marseille : prix médian, surface, revenu, population, transactions, **années de revenu**, m²/an, classe d'abordabilité : avec export CSV.

Pourquoi : la carte est faite pour explorer, le tableau pour **comparer et classer** précisément (« trier tous les arrondissements du plus abordable au plus tendu »). C'est aussi la seule vue qui exploite la granularité **infra-communale** de la couche Gold, essentielle pour un choix intra-Paris.




Fig. 2 : Tableau des arrondissements. Comparaison triable colonne par colonne (ici Paris, par prix décroissant) ; la pastille colorée encode la classe d'abordabilité, export CSV en un clic.

III.6 La synthèse textuelle

Un **moteur à base de règles** (seuils + gabarits, sans IA) traduit les chiffres d'une commune en analyse rédigée : un paragraphe de synthèse puis des cartes thématiques (abordabilité, marché, transport, équipements, démographie, tendance), chacune comparée à la moyenne nationale et colorée par tonalité (favorable / neutre / vigilance).

Pourquoi : toute la richesse des données ne sert à rien si l'utilisateur ne sait pas l'interpréter. La synthèse rend la donnée **lisible pour un non-expert** ; basée sur des règles, elle est **déterministe et explicable** (même entrée → même texte), contrairement à une génération par LLM.

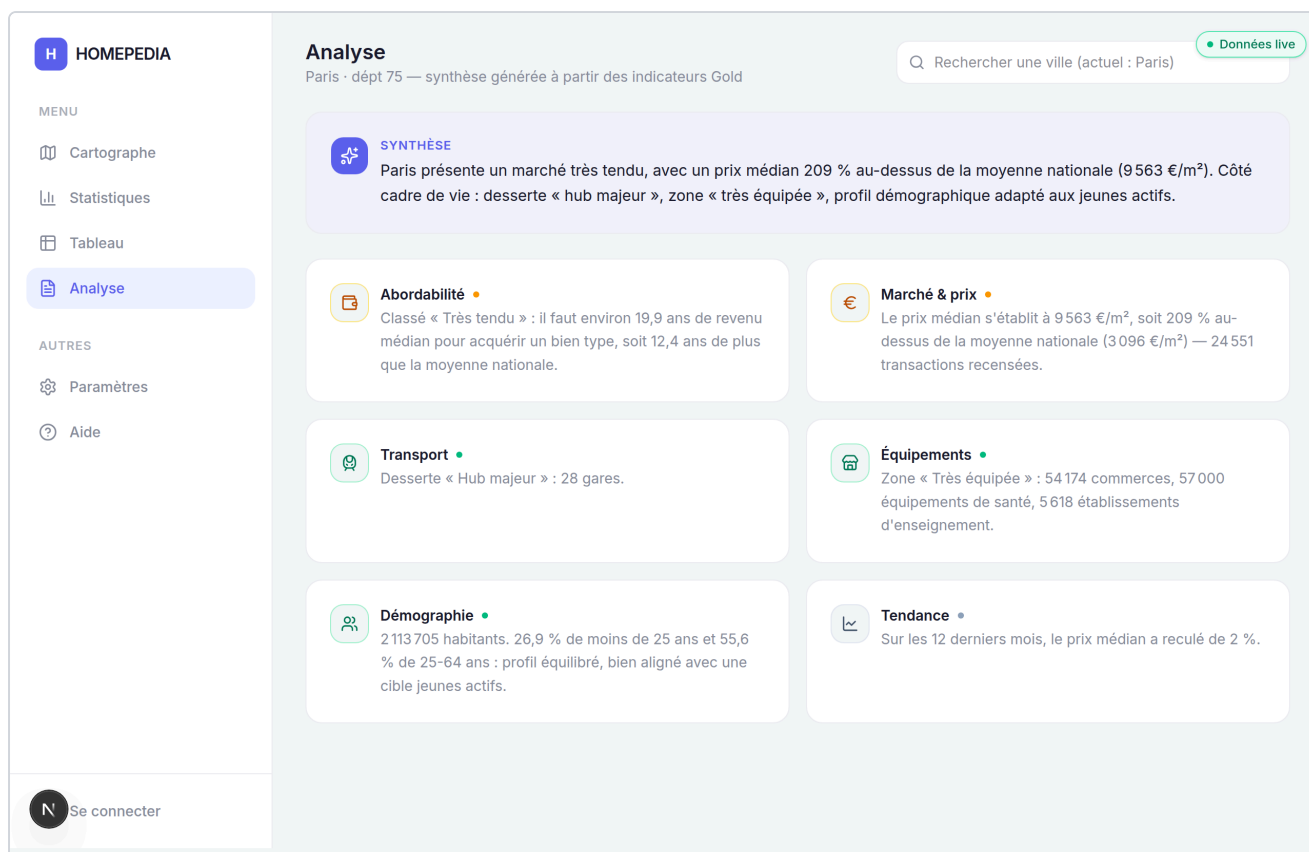


Fig. 3 : Analyse textuelle. Une synthèse de tête puis une carte par thème (abordabilité, marché, transport, équipements, démographie, tendance), chacune comparée à la moyenne nationale et colorée par tonalité.

IV. Justification des règles métier : pourquoi ces choix ?

Au-delà du *comment* (annexe en fin de rapport), chaque règle a été retenue pour trois qualités : rester **lisible** pour un non-expert, **robuste** aux défauts des données ouvertes, et **comparable** d'une commune à l'autre. Pour chacune, on explicite l'**alternative écartée** et la raison.

IV.1 Prix médian & filtrage DVF

Médiane, pas moyenne.

Pourquoi : les prix immobiliers forment une distribution **asymétrique à droite** (quelques ventes de luxe). La médiane reflète la transaction *typique* que rencontrera l'acheteur.

Plutôt que : la moyenne, tirée vers le haut par les biens d'exception, gonfle le prix « normal » et fausse la comparaison entre communes.

Bornes anti-aberrant [500 ; 20 000] €/m².

Pourquoi : DVF contient des erreurs de saisie et des mutations non-standard (parkings, dépendances) aux €/m² absurdes ; des bornes fixes les écartent de façon **stable et reproductible**.

Plutôt que : un filtrage statistique par commune (IQR / z-score) serait instable sur les communes à faible volume de ventes et moins auditable.

Filtre « mono-bien ».

Pourquoi : une mutation peut regrouper plusieurs lots (vente d'immeuble) : son €/m² global n'a pas de sens. On ne garde que les ventes d'un **logement unique**, seules réellement comparables.

Plutôt que : diviser la valeur totale par la surface d'une vente multi-lots injecterait un prix au m² bruité et biaisé.

IV.2 Abordabilité (années de revenu, classes)

Logement type fixe de 70 m².

Pourquoi : figer la taille du « panier » rend les communes comparables sur un **même bien de référence** (≈ 2-3 pièces, cible d'un jeune ménage).

Plutôt que : indexer sur la surface médiane *locale* mélangerait « moins cher » et « plus petit », cassant la comparabilité inter-communes.

Années de revenu = $\text{prix_m2} \times 70 / \text{revenu_median}$.

Pourquoi : « combien d'années de revenu pour un logement type » est **intuitif et sans hypothèse** de taux ni de durée de prêt : donc explicable et stable dans le temps.

Plutôt que : un taux d'effort mensuel (mensualité ÷ revenu) dépendrait du taux d'intérêt et de la durée du prêt : plus fragile, daté, et moins pédagogique.

Seuils 7 / 12 / 18 ans.

Pourquoi : ancrés sur des repères d'accession réels : <7 finançable confortablement, 7-12 territoire d'un prêt standard (20-25 ans, effort tenable), 12-18 tendu, ≥18 hors de portée pour un jeune acheteur. Des seuils **absolus** donnent une lecture stable dans le temps et l'espace.

Plutôt que : des classes par quantiles de la distribution ne seraient pas comparables d'une année ou d'une région à l'autre, et « 3^e quartile » ne parle pas à un acheteur.

IV.3 Transport & équipements

Desserte 100 / 80 / 55 / 10 + pénalité au-delà de 2 km.

Pourquoi : barème **non-linéaire** : l'écart hub ↔ bien desservie est faible, mais « non desservie » est quasi rédhibitoire pour un jeune actif sans voiture. Le seuil de 2 km ≈ distance à pied/vélo raisonnable vers la gare.

Plutôt que : un espacement linéaire égal traiterait « non desservie » comme un simple cran de moins ; ignorer la distance ferait scorer pareil deux communes « desservies » avec une gare à 0,2 km et à 3 km.

Niveau d'équipement 100 / 75 / 50 / 20.

Pourquoi : classes dérivées des comptages BPE, avec un **plancher bas (20)** qui marque nettement une commune sous-équipée dans le score.

Plutôt que : le comptage brut d'équipements n'est pas normalisé (une grande ville domine mécaniquement) et n'est pas combinable aux autres notes.

IV.4 Score de correspondance

Moyenne pondérée par curseurs, dimensions manquantes exclues.

Pourquoi : l'arbitrage (budget vs transport...) **appartient à l'utilisateur** ; exclure une dimension sans donnée évite de pénaliser une commune pour un simple trou de données.

Plutôt que : des poids fixes ne seraient pas personnels (contraire à la « carte à son image ») ; imputer les valeurs manquantes introduirait un biais silencieux.

Jeunes actifs : 50 % → 0, 85 % → 100.

Pourquoi : bornes plausibles de la part active : en-dessous de 50 % la zone vieillit, 85 % = très jeune/active. Un rescale linéaire entre ces bornes donne une note 0-100 **combinable**.

Plutôt que : le pourcentage brut n'est pas normalisé et ne se combine pas aux trois autres notes.

IV.5 Analyse textuelle : règles plutôt que LLM

Moteur à seuils + gabarits, déterministe.

Pourquoi : reproductible (même entrée → même texte), **explicable et auditable**, sans hallucination ni coût/latence d'API : indispensable pour un rendu où chaque phrase doit être justifiable.

Plutôt que : une génération par LLM serait non-déterministe, risquerait d'inventer des chiffres, et serait plus difficile à défendre et à reproduire.

V. Annexe : Comment chaque métrique est calculée

Métrique	Calcul	Source · Millésime
Prix médian au m² prix_m2_median	Filtre « mono-bien », puis prix_m2 = valeur_fonciere / surface_reelle_bati, bornes anti-aberrant [500 ; 20 000] €, puis médiane par commune × année.	DVF (Etalab) · 2021/2022/2024
Années de revenu affordability_years	prix_m2 × 70 / revenu_median : nombre d'années de revenu médian pour un logement type de 70 m².	DVF × FiLoSoFi · revenu 2023
m² par an m2_par_an	revenu_median / prix_m2 : m² achatables avec un an de revenu médian.	DVF × FiLoSoFi

Métrique	Calcul	Source · Millésime
Classe d'abordabilité affordability_class	Seuils sur les années de revenu : Très abordable <7 · Abordable 7–12 · Tendu 12–18 · Très tendu ≥18.	Dérivé de affordability_years
Desserte desserte_class	Segment SNCF de la gare (A = Hub majeur, B = Bien desservie, C = Desservie) ; sans gare → Non desservie + distance haversine à la plus proche.	SNCF open data · 2024
Niveau d'équipement niveau_equipement	Dérivé des comptages d'équipements (Santé, Commerces, Enseignement, Supermarchés...) par commune → Sous-équipée ... Très équipée.	BPE (INSEE)
Structure par âge pct_moins25 / 25_64 / 65plus	Parts (%) de tranches d'âge disjointes, agrégées en 3 classes.	Recensement INSEE · 2022
Score de correspondance (calculé côté front)	Moyenne pondérée de 4 notes 0–100 (budget, transport, services, jeunes actifs) par les curseurs d'importance de l'utilisateur : détail et exemple dans l'encadré « pas à pas » (III.1).	Front · scoring.ts
Variation mensuelle (Δ)	Écart en % entre les deux derniers mois disponibles de la série de tendance.	DVF (trend mensuel)

Les métriques catégorielles (abordabilité, desserte, équipement, démographie) sont pré-calculées dans la couche Gold et lues par l'API ; le score de correspondance et les variations sont calculés côté front.

Sources : docs/fiche_ville.md, docs/silver_dvf_logic.md, frontend/src/lib/scoring.ts, analysis.ts, map-modes.ts.

HOMEPIEDIA · Epitech T-DAT-902.